

智联计算系统

基于大模型的智能任务调度与自动部署平台

核心功能汇报

系统概述

智联计算系统通过自然语言对话完成计算任务的全流程自动化：

- 用户用自然语言描述任务需求（节点、时间、规模、策略）
- 大模型（通义千问 qwen3-max）解析意图，提取结构化参数
- 确认后自动生成路由 DAG，外部路由系统分配物理节点
- 按调度时间自动启动容器，任务完成后自动采集业务指标



图1：系统登录页 — 普通用户进入意图解析对话，管理员进入部署管理后台

功能一：自然语言意图解析

用户无需填写表单，直接用自然语言描述任务。系统通过确定性工作流程控制大模型行为：

- 大模型只负责参数提取，不自由发挥
- 验证层（_validate_and_clean）拦截幻觉输出，节点名必须在数据库中存在

- 参数不完整时系统主动追问，完整后出现确认按钮




图2：用户输入自然语言任务描述



图3：大模型解析完成，右侧面板实时展示结构化参数，确认按钮出现

功能二：路由系统对接

用户确认提交后，系统自动完成以下操作：

- 生成三节点 DAG (source → compute → sink)，含资源需求 (CPU/GPU/内存)
- 工单写入数据库，routing_status = pending，供外部路由系统扫表
- 外部路由系统通过 GET /api/orders?routing_status=pending 获取待路由工单
- 路由完成后调用 POST /api/orders/{id}/routing-result 回写节点分配和 GPU 编号

路由结果接口格式：

字段	说明	示例
node_id	逻辑节点角色	source / compute / sink
worker_host	分配的物理节点	compute-2
gpu_device	GPU 编号（可为空）	"0" 或 null

功能三：定时自动部署

收到路由结果后，系统自动创建 TaskInstance 并注册定时任务：

- APScheduler 在 business_start_time 自动调用 DAGExecutor 启动容器
- 逐节点 HTTP 推送给 node_agent，node_agent 在目标机器执行 docker run
- GPU 编号通过环境变量 GPU_DEVICE 注入容器
- 到 business_end_time 自动停止容器，触发业务指标采集




图4：用户端工单列表 — 展示任务类型、路由策略、部署状态、调度时间

功能四：管理后台业务中心

管理员可查看所有用户的工单，包含完整的业务指标和评估结果：

- 工单列表：任务类型、路由策略、工单状态、部署状态、目标/实际值、达标状态
- 工单详情：业务参数、路由结果、部署实例、计算结果（4 Tab）
- 业务指标统计：按任务类型和路由策略分组，展示成功率




图5：管理后台业务中心 — 全局工单视图，含业务指标统计

功能五：业务指标自动采集与评估

任务停止后，系统自动完成指标采集和业务目标评估：

- 容器上报计算耗时到 POST /api/metrics
- 系统对比实际耗时与目标值 (business_objective.target_value)
- 写入 business_objective_evaluations 表，business_success 字段标记是否达标
- 用户端详情"结果" Tab 展示：输入参数、计算输出、一致性校验、耗时验收

矩阵乘法任务结果展示包含：

- 输入参数（矩阵大小、批次、精度）
- 计算输出（实际耗时、GFLOPS、结果一致性）
- 耗时验收结论（达标/超标 + 具体数值对比）

系统架构总结

层次	组件	技术栈
前端	意图对话 + 工单管理	Vue3 + Element Plus

后端	FastAPI + 调度器	Python + APScheduler
大模型	意图解析	qwen3-max (DashScope)
路由系统	节点分配（外部）	REST API 对接
节点代理	容器管理	node_agent + Docker
数据库	工单/实例/指标	MySQL + SQLAlchemy